

# Рекомендательная система курсов на графах

Ахтямов Алексей (mralexheimk@yandex.ru)

October 20, 2022

## Введение

В текущем документе описывается построение эффективной конфигурации базы данных PostgreSQL с таблицами курсов и тэгов, создание рекомендательной системы курсов, основанной на графах и извлечение тэгов из пользовательского ввода (в поле поиска курсов) с помощью расстояния Левенштейна. Реализация на Python представлена тут [GitHub](#).

## Структура базы данных

База данных будет содержать 2 таблицы ('coursers' и 'tags')

### Coursers:

Тип: *динамически обновляемая*

Пример создания 'coursers' таблицы с помощью SQL запроса (нам важны только столбцы **id**, **title** (название курса) и **tags** (тэги)):

```
1 CREATE TABLE courserts (  
2     id SERIAL PRIMARY KEY,  
3     title VARCHAR (255) NOT NULL,  
4     author VARCHAR (255) NOT NULL,  
5     views INTEGER NOT NULL,  
6     likes INTEGER NOT NULL,  
7     tags TEXT NOT NULL)
```

Таблица будет содержать список добавленных курсов.  
Столбец **tags** содержит набор строк (тэгов), разделенных специальным символом (в нашей реализации это символ '@').

### Tags:

Тип: *периодически обновляемая*

Создание **'tags'** таблицы с помощью SQL запроса:

Заполнение происходит периодически из таблицы **'coursers'**

```
1 CREATE TABLE tags (  
2     id SERIAL PRIMARY KEY,  
3     tag VARCHAR(255) UNIQUE NOT NULL,  
4     coursers_count INTEGER NOT NULL,  
5     related_tags TEXT)
```

Таблица будет хранить список всех тэгов.

Столбец **coursers\_count** хранит число курсов, использующих тэг.

Столбец **related\_tags** хранит индексы тэгов, связанных с текущим.

Для ускорения обновления таблицы и ограничения числа смежных вершин в графе введем ограничение на количество тэгов, связанных с текущим.

Обозначим это ограничение сверху как **maxRelatedTags**. При периодическом обновлении таблицы в столбец **related\_tags** войдут индексы тех тэгов, **coursers\_count** которых в таблице наибольший.

## Построение графа

[Визуальный пример](#) графа с тэгами и курсами.

Обозначим число курсов как **coursersCount**, а число тэгов как **tagsCount**.

Граф - множество вершин, соединенных между собой каким-то образом.

Ориентированный граф - граф, с ориентированным соединением между вершинами.

Вершинами нашего графа будут все тэги и все курсы ( $tagsCount + coursersCount$ ).

Каждая вершина имеет максимум **maxRelatedTags** выходящих из нее ребер, ведущих к вершинам-тэгам и максимум **coursersCount** выходящих ребер, ведущих к вершинам-курсам.

В худшем случае, когда каждый тэг есть в каждом курсе, используемая для хранения графа память равна  $O(V+E) = O((tagsCount+coursersCount) + (tagsCount + coursertsCount) * (maxRelatedTags + coursertsCount))$

Перебирая значения двух переменных при  $maxRelatedTags = 5$  получаем:

	<b>coursersCount</b>	<b>tagsCount</b>	<b>Memory</b>
<b>0</b>	1.000e+03	2.000e+04	2.113e+07
<b>1</b>	2.000e+03	4.000e+04	8.425e+07
<b>2</b>	5.000e+03	1.000e+05	5.256e+08
<b>3</b>	1.000e+04	2.000e+05	2.101e+09
<b>4</b>	5.000e+04	1.000e+06	5.251e+10
<b>5</b>	2.000e+05	4.000e+06	8.400e+11
<b>6</b>	5.000e+05	1.000e+07	5.250e+12
<b>7</b>	1.000e+06	2.000e+07	2.100e+13

Для хранения графа с миллионом курсов и 20-ти миллионами тэгов требуемая память составляет  $\sim 2 \cdot 10^{13}$  бит (40000 ГБ).

Пусть **averageCoursersOnTag** - среднее число курсов, содержащих определенный тэг.

В среднем случае, требуемая память составляет  $O((tagsCount+coursersCount) + (tagsCount+coursersCount)*(maxRelatedTags+averageCoursersOnTag))$

Перебирая значения двух переменных при  $maxRelatedTags = 5$  получаем:

	<b>coursersCount</b>	<b>tagsCount</b>	<b>averageCoursersOnTag</b>	<b>Memory</b>
<b>0</b>	1.000e+03	2.000e+04	20	5.460e+05
<b>1</b>	2.000e+03	6.000e+04	30	2.232e+06
<b>2</b>	5.000e+03	2.000e+05	40	9.430e+06
<b>3</b>	1.000e+04	5.000e+05	50	2.856e+07
<b>4</b>	5.000e+04	3.000e+06	60	2.013e+08
<b>5</b>	2.000e+05	1.400e+07	70	1.079e+09
<b>6</b>	5.000e+05	4.000e+07	80	3.483e+09
<b>7</b>	1.000e+06	9.000e+07	90	8.736e+09

Для хранения графа с миллионом курсов и 90-та миллионами тэгов требуемая память составляет  $\sim 9 \cdot 10^9$  бит (4 ГБ).

Инициализация графа происходит периодически после обновления таблицы 'tags'.

## Обработка пользовательского ввода

Для поиска тэгов в пользовательской строке разобьем строку на слова (разделенные пробелом) переберем все размещения из количества слов по  $i$ ,  $\forall i \leq \maxWordsInTag$  (**maxWordsInTag** - максимальное число слов в тэге, в нашей реализации оно равно 3).

В каждом размещении объединим слова в строку и с помощью бинарного поиска найдем окрестность похожих на нее тэгов. Выберем из них тот, расстояние по Левенштейну до которого минимально и, если это расстояние меньше какой-то верхней границы - берем этот тэг для дальнейшей рекомендации по нему.

Расстояние Левенштейна - минимальное число операций (удаление, вставка и замена символа), необходимых для превращения одной строки в другую. Чем оно меньше - тем более похожи строки. В нашей реализации, для избежания эквивалентности коротких тэгов, операция замены стоит в 2 раза больше других операций.

После обработки мы получим список тэгов, по которым мы будем рекомендовать пользователю курсы.

## Рекомендация курсов

После получения списка тэгов, добавим в этот список семантически частные тэги.

В нашем графе, если вершина-тэг  $A$  идет в вершину-тэг  $B$  означает, что  $B$  - более высокая абстракция над  $A$  или, по-другому,  $A$  - частный случай  $B$ .

Для добавления новых тэгов, переберем все смежные вершины-тэги в графе у списка тэгов и добавим в список. Прделаем эту операцию столько раз, какую глубину мы указали в конфигурации.

В итоге, мы имеем список тэгов и информацию о том, на какой глубине получен этот тэг. Переберем все эти тэги в графе и найдем все смежные вершины-курсы и добавим в нашу рекомендацию. В зависимости от глубины, ключевых слов в названии курса или рейтинга сформируем и отсортируем список рекомендуемых курсов.